

Архитектура система

У овом поглављу приказан је начин на који су изграђени финални модели за предвиђање нивоа депресије, односно како су алгоритми описани у теоријским основама комбиновани и примењени у пракси како би се добили најбољи резултати. Основни улаз у било који модел чине аудио записи клиничких интервјуа или њихови текстуални транскрипти, док је очекивани излаз модела једна нумеричка вредност која представља процењену оцену на PHQ-8 скали (од 0 до 24).

На високом нивоу апстракције, архитектура решења се састоји из две независне гране: једне за анализу акустичких карактеристика и друге за анализу текстуалних транскрипата. Обе гране започињу фазом учитавања и претпроцесирања улаза из скупа података, након чега се врши екстракција обележја (било традиционалним методама попут MFCC-а и TF-IDF-а, или помоћу дубоког учења и Трансформера). Скуп података и претпроцесирање су исти за сваки модел, а алгоритам за екстракцију обележја је оно што је посебно за сваки развијен модел. Добијена обележја се затим прослеђују моделима машинског учења или неуронским мрежама који на основу тих обележја врше финалну регресију и враћају предвиђену PHQ-8 оцену. У циљу проналаaska најбољих регресионих алгоритама машинског учења и њихових хиперпараметара, коришћен је RandomizedSearchCV. За званичан пример модела одабрен је онај регресиони алгоритам и његови хиперпараметри који имају најбољу комбинацију MAE, RMSE и Пирсоновог коефицијента корелације. Слика у наставку илуструје ток података у систему.




Figure 1: Ток података на високом нивоу

Сходно томе, ово поглавље биће подељено на скуп података, заједничко претпроцесирање, алгоритми за екстракцију важних обележја и алгоритме машинског учења за регресију.

Сви описани алгоритми имплементирани су у програмском језику Пајтон (енг. *Python*), коришћењем стандардних библиотека за обраду података и машинско учење. За рад са звуком примарно је коришћена библиотека *librosa*, док је за текст коришћен *nlTK*.

Традиционални модели машинског учења имплементирани су помоћу `scikit-learn` библиотеке, док су архитектуре дубоког учења изграђене у `PyTorch` оквиру. За екстракцију напредних текстуалних и аудио репрезентација коришћена је библиотека `transformers` компаније *Hugging Face*, као и `sentence-transformers`.

Скуп података

Претпроцесирање

Алгоритми за екстракцију важних обележја

Регресиони алгоритми машинског учења

Акустички модели

Овај модул система фокусира се искључиво на анализу звучних записа клиничких интервјуа. У оквиру овог модула испробано је неколико различитих приступа, почевши од традиционалних метода машинског учења, преко конволутивних неуронских мрежа, до употребе напредних аудио Трансформер модела.

Традиционални алгоритми машинског учења

Овај приступ (имплементиран у скрипти `traditional_ml_sound.py`) представља основну (енг. *baseline*) методу за предвиђање депресије из звука.

- **Ток података и архитектура:** Звучни записи се учитавају при брзини одабирања од 16 kHz и конвертују у један канал. Из њих се екстрахује 40 Мел-фреквенцијских кепстралних коефицијената (MFCC). Због променљиве дужине аудио записа, они су подељени на фиксне временске прозоре дужине 30 секунди (са преклапањем од 30 секунди). За сваки прозор рачунају се статистичке мере: средња вредност, стандардна девијација, минимум и максимум, како за саме MFCC коефицијенте, тако и за њихове прве и друге изводе (делта и делта-делта карактеристике). Ове статистике се спајају у један вектор за сваког пацијента и прослеђују регресионим алгоритмима попут Регресије потпорних вектора (SVR), Еластичне мреже (ElasticNet) и Случајних шума (Random Forest). За оптимизацију хиперпараметара ових алгорита коришћена је метода насумичне претраге (RandomizedSearchCV).

Конволутивне неуронске мреже (CNN)

С обзиром на то да MFCC репрезентације звука могу да се посматрају као дводимензионалне слике (спектрограми), имплементирана је 2D CNN архитектура (у скрипти `cnn_approach.py`).

- **Ток података и архитектура:** Сигнал је подељен на краће прозоре од 10 секунди (са преклапањем на 5 секунди) из којих је извучено 40 MFCC коефицијената уз њихове делта и делта-делта изводе, чиме је формирана улазна матрица са три канала (слично RGB сликама). Дизајнирана је CNNRegressor мрежа која се састоји од три конволутивна блока. Сваки блок садржи конволутивни слој (са керналом величине 3times3), групну нормализацију (енг. *GroupNorm*) ради стабилизације тренинга, ReLU активациону функцију и слој за сажимање (енг. *MaxPool2d*). Након њих следе потпуно повезани линеарни слојеви (MLP) који дају предвиђени PHQ-8 скор. Модел је оптимизован минимизацијом MSE (Средња квадратна грешка) функције губитка.

Екстракција дубоких аудио репрезентација и машинско учење

Како би се искористила моћ само-надгледаног учења, тестирана су четири различита претходно тренирана аудио Трансформер модела чија су излазна обележја (енг. *embeddings*)

коришћена као улаз за традиционалне ML регресоре. Сваки модел има своју конфигурациону скрипту која позива заједнички цевовод (енг. *pipeline*):

- **wav2vec2_approach.py**: Користи facebook/wav2vec2-base-960h.
- **hubert_approach.py**: Користи facebook/hubert-base-ls960.
- **wavlm_approach.py**: Користи microsoft/wavlm-base-plus.
- **audeering_approach.py**: Користи модел компаније Audeering фино подешен за препознавање емоција (audeering/wav2vec2-large-robust-12-ft-emotion-msp-dim).
- **Ток података**: Звук се дели на прозоре дужине 5 секунди. За сваки прозор, Трансформер модел генерише густе векторе карактеристика. Сви добијени вектори једног пацијента се агрегирају (усредњавањем) и прослеђују алгоритмима попут Ridge, Lasso, ElasticNet, SVR и Random Forest за предвиђање финалног скорa.

Архитектуре базиране на дубоком учењу над Трансформер обележјима

Уместо коришћења једноставних ML алгоритама, развијене су и напредне неуронске мреже које уче да на паметнији начин комбинују извучена дубока обележја:

- **Аутоенкодер и механизам пажње (audeering_deep_approach.py)**: Користи обележја из Audeering модела. Прво се примењује WindowAutoencoder да сажме димензионалност излазних вектора како би се елиминисао шум (уз MSE функцију губитка за реконструкцију). Затим се сажети вектори прослеђују кроз AttentionPoolRegressor који користи механизам пажње (енг. *Self-Attention*) да агрегира све временске прозоре додељујући већу тежину онима који садрже највише депресивних индикатора. Током претпроцесирања, користи се и Гаусов шум малог интензитета као техника аугментације.
- **Трансформер над Трансформером (transformer_pool_approach.py)**: Овај приступ узима секвенцу екстрахованих вектора за једног пацијента и пропушта их кроз додатни Трансформер енкодер (енг. *TransformerEncoder*) како би се ухватиле дугорочне временске зависности у говору. Након тога следи слој линеарне пажње који сажима секвенцу у један вектор за финалну регресију.

Анализа емоција у временским прозорима

Овај приступ (скрипта emotion_windows_approach.py) ослања се директно на класификацију емоција из говора.

- **Ток података и архитектура**: Коришћен је модел ehcalabres/wav2vec2-lg-xlsr-en-speech-emotion-recognition који за прозоре од 5 секунди враћа вероватноће за 8 различитих емоција (љутња, смиреност, гађење, страх, срећа, неутралност, туга, изненађење). За цео транскрипт рачунају се статистике ових вероватноћа (средња вредност, минимум, максимум, стандардна девијација) и формира се коначни вектор карактеристика који се прослеђује класичним регресионим алгоритмима.

Текстуални модели

За разлику од звука, текстуални транскрипти носе директне семантичке информације о ономе шта је пацијент изговорио. Овај модул истражује традиционалне моделе, напредне језичке Трансформере и технике учења без претходних примера (Zero-shot).

Традиционални модели и TF-IDF репрезентација

Овај приступ (скрипта transcript_traditional_ml_regression.py) ослања се на “врећу речи” представљену кроз матрицу фреквенција.

- **Ток података и архитектура**: Текст се токенизује уз уклањање неалфанумеричких карактера и претварање у мала слова. Примењује се WordNetLemmatizer и уклањају се стоп-речи. Обрађен текст векторизује се помоћу TfidfVectorizer-a. Како би се смањила димензионалност и спречило преприлагођавање, примењује се TruncatedSVD. Добијени

вектори се прослеђују алгоритмима као што су Ridge, Bayesian Ridge, SVR и Gradient Boosting.

Комбиновани TF-IDF и Трансформер приступ

У скрипти `transcript_mpnnet_lemma_tfidf_regression.py` имплементирана је хибридна метода.

- **Ток података:** Уместо коришћења целог транскрипта, прво се користи TF-IDF како би се идентификовао фиксни број најрелевантнијих лематизованих речи (нпр. топ 50 речи) за сваког пацијента. Те речи се спајају у кратак текст који се затим пропушта кроз `all-mpnnet-base-v2` Трансформер модел. Овако добијена густа репрезентација фокусирана искључиво на кључне речи се на крају користи у класичним ML регресорима.

Напредни језички Трансформери са традиционалним регресорима

Како би се сачувао контекст и редослед речи, коришћени су претходно тренирани Трансформер модели за генерисање густих репрезентација целих реченица и пасуса. Због ограничења Трансформера у дужини текста, транскрипти се деле на мање сегменте (енг. *chunks*) са преклапањем, што уједно служи и као аугментација података.

- **`transcript_transformer_regression.py`:** Текст се дели на сегменте. За сваки сегмент генерише се ембединг помоћу `all-mpnnet-base-v2` модела (коришћењем библиотеке `sentence-transformers`). Ембединзи свих сегмената једног пацијента се усредњавају у један финални вектор и прослеђују ML алгоритмима.
- **`transcript_bert_regression.py`:** Исти принцип се примењује коришћењем основног `bert-base-uncased` модела (имплементирано преко `AutoModel` и `AutoTokenizer` класа), где се скривени стања Трансформера усредњавају ради добијања репрезентације.

Регресија заснована на емоцијама у тексту

Приступ из скрипте `transcript_emotion_regression.py` инспирисан је сличном идејом као и код акустичких модела, али се примењује на текст.

- **Ток података:** Текст се дели на сегменте, а за сваки сегмент се позива модел `j-hartmann/emotion-english-distilroberta-base`. Овај модел враћа дистрибуцију вероватноћа за 7 различитих емоција. Вероватноће свих сегмената се усредњавају, чиме се пацијент представља преко свог “емоционалног профила” (вектор од 7 елемената), који потом служи као улаз за традиционалну ML регресију.

Анализа лингвистичких карактеристика

У скрипти `transcript_enhanced_analysis.py` покушано је обogaћивање дубоких репрезентација експлицитним лингвистичким правилима.

- **Ток података:** За сваки транскрипт се паралелно екстрахују семантички Трансформер вектори и мануелно дефинисане карактеристике (попут броја јединствених речи и стопе појављивања речи повезаних са негативним емоцијама из унапред дефинисаног речника). Ова два скупа карактеристика се конкатенирају пре уласка у коначни регресор.

Фино подешавање Трансформера (енг. *Fine-Tuning*)

Скрипта `transcript_fine_tune_transformer_regression.py` користи приступ дубоког учења с краја на крај (енг. *end-to-end*).

- **Ток података и архитектура:** Овде се модел `distilroberta-base` фино подешава директно за задатак регресије. Транскрипти су подељени у сегменте од 150 речи (са преклапањем од 100 речи), где сваки сегмент наслеђује исти RNQ-8 скор као и цео транскрипт. Модел се тренира коришћењем HuggingFace Trainer АПИ-ја уз средњу апсолутну грешку (MAE) као метрику. Током евалуације, предвиђања за све сегменте

једног пацијента се агрегирају (усредњавањем) како би се добио коначни скор. Ово омогућава Трансформеру да прилагоди своје унутрашње тежине специфичном речнику депресивних пацијената.

Комплетне дубоке архитектуре са механизмом пажње

У оквиру скрипте `transcript_full_deep_learning_regression.py` изграђена је прилагођена PyTorch архитектура.

- **Архитектура мреже:** За разлику од простог усредњавања сегмената, ова мрежа (AttentionRegressor са _AttentionPoolNet модулом) користи механизам пажње над MPNet векторима. Мрежа се састоји од вишеслојног перцептрона (MLP) са Tanh активацијом који рачуна “тежину” или “важност” сваког сегмента текста. Мрежа се тренира уз MSELoss функцију губитка како би научила који делови интервјуа (нпр. када пацијент директно говори о симптомима) носе највише информација за регресију.

Zero-shot учење помоћу великих језичких модела

У оквиру скрипте `transcript_prompt_zeroshot_regression.py` имплементиран је потпуно другачији приступ заснован на Prompt инжењерингу.

- **Ток података и архитектура:** Коришћен је велики језички модел `google/flan-t5-base`. Транскрипти су дељени на дугачке сегменте (око 300 речи) како би се уклопили у контекстни прозор. Уместо тренирања мреже, моделу је прослеђен системски упит са задатком да, у улози клиничког психолога, процени присутност сваког од 8 симптома депресије на скали од 0 до 3, на основу прочитаног текста. Модел користи своје опште знање о језику како би директно генерисао одговоре без икаквог додатног тренинга на овом скупу података.
- **Сумирање:** Финални скор добија се једноставним сабирањем оцена за свако појединачно питање (симптом) на нивоу сегмента, а потом просеком тих сума за целог пацијента.