



УНИВЕРЗИТЕТ У НОВОМ САДУ
ФАКУЛТЕТ ТЕХНИЧКИХ
НАУКА У НОВОМ САДУ



Веселин Рогановић

Предвиђање нивоа депресије на основу клиничких интервјуа применом машинског учења

ЗАВРШНИ РАД

Основне академске студије

Нови Сад, 2026

	УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА 21000 НОВИ САД, Трг Доситеја Обрадовића 6	Број:
	ЗАДАТАК ЗА ЗАВРШНИ РАД	Датум:

(Податке уноси предметни наставник - ментор)

Студијски програм:	Софтверско инжењерство и информационе технологије		
Студент:	Веселин Рогановић	Број индекса:	SV 36/2022
Степен и врста студија:	Основне академске студије		
Област:	Електротехничко и рачунарско инжењерство		
Ментор:	Милан Сегедицац		
НА ОСНОВУ ПОДНЕТЕ ПРИЈАВЕ, ПРИЛОЖЕНЕ ДОКУМЕНТАЦИЈЕ И ОДРЕДБИ СТАТУТА ФАКУЛТЕТА ИЗДАЈЕ СЕ ЗАДАТАК ЗА ЗАВРШНИ РАД, СА СЛЕДЕЋИМ ЕЛЕМЕНТИМА: - проблем – тема рада; - начин решавања проблема и начин практичне провере резултата рада, ако је таква провера неопходна;			

НАСЛОВ ЗАВРШНОГ РАДА:

Предвиђање нивоа депресије на основу клиничких интервјуа применом машинског учења
--

ТЕКСТ ЗАДАТКА:

Lorem ipsum dolor sit amet, consectetur adipiscing elit, sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim aenean sit amet, nunc malesuada accumsan dictum euismod. Quod idem licet transferre in voluptatem, ut postea variari voluptas distinguere possit, augeri amplificarique non possit. At etiam Athenis, ut e patre audiebam facete et urbane Stoicos irridente, statua est in quo a nobis philosophia defensa et collaudata est, cum id, quod maxime placeat, facere possimus, omnis voluptas assumenda est, omnis dolor repellendus. Temporibus autem quibusdam et.

Руководилац студијског програма:	Ментор рада:

Примерак за: ☐ - Студента; ☐ - Ментора
--

	УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА 21000 НОВИ САД, Трг Доситеја Обрадовића 6	
	КЉУЧНА ДОКУМЕНТАЦИЈСКА ИНФОРМАЦИЈА	

Редни број, РБР:		
Идентификациони број, ИБР:		
Тип документације, ТД:		Монографска документација
Тип записа, ТЗ:		Текстуални штампани материјал
Врста рада, ВР:		Дипломски - бечелор рад
Аутор, АУ:		Веселин Рогановић
Ментор, МН:		Др Милан Сегединац, редовни професор
Наслов рада, НР:		Предвиђање нивоа депресије на основу клиничких интервјуа применом машинског учења
Језик публикације, ЈП:		српски/ћирилица
Језик извода, ЈИ:		српски/енглески
Земља публиковања, ЗП:		Република Србија
Уже географско подручје, УГП:		Војводина
Година, ГО:		2026
Издавач, ИЗ:		Ауторски репринт
Место и адреса, МА:		Нови Сад, трг Доситеја Обрадовића 6
Физички опис рада, ФО: (поглавља/страница/ цитата/табела/слика/графика/прилога)		6/45/41/0/3/0/2
Научна област, НО:		Електротехничко и рачунарско инжењерство
Научна дисциплина, НД:		Примењене рачунарске науке и информатика
Предметна одредница/Кључне речи, ПО:		Шаблон, завршни рад, упутство
УДК		
Чува се, ЧУ:		У библиотеци Факултета техничких наука, Нови Сад
Важна напомена, ВН:		
Извод, ИЗ:		Овај документ представља упутство за писање завршних радова на Факултету техничких наука Универзитета у Новом Саду. У исто време је и шаблон за Turpst.
Датум прихватања теме, ДП:		
Датум одбране, ДО:		01.01.2025
Чланови комисије, КО:	Председник:	Др Петар Петровић, ванредни професор
	Члан:	Др Марко Марковић, доцент
	Члан:	
	Члан, ментор:	Др Милан Сегединац, редовни професор
		Потпис ментора

	UNIVERSITY OF NOVI SAD • FACULTY OF TECHNICAL SCIENCES 21000 NOVI SAD, Trg Dositeja Obradovića 6	
	KEY WORDS DOCUMENTATION	
Accession number, ANO :		
Identification number, INO :		
Document type, DT : Monographic publication		
Type of record, TR : Textual printed material		
Contents code, CC :		
Author, AU : Veselin Roganović		
Mentor, MN : Milan Segedinac, Phd., full professor		
Title, TI : Predicting depression severity from clinical interviews using machine learning		
Language of text, LT : Serbian		
Language of abstract, LA : Serbian/English		
Country of publication, CP : Republic of Serbia		
Locality of publication, LP : Vojvodina		
Publication year, PY : 2026		
Publisher, PB : Author's reprint		
Publication place, PP : Novi Sad, Dositeja Obradovica sq. 6		
Physical description, PD : (chapters/pages/ref./tables/pictures/graphs/appendixes) 6/45/41/0/3/0/2		
Scientific field, SF : Electrical and Computer Engineering		
Scientific discipline, SD : Applied computer science and informatics		
Subject/Key words, S/KW : Template, thesis, tutorial		
UC		
Holding data, HD : The Library of Faculty of Technical Sciences, Novi Sad		
Note, N :		
Abstract, AB : This document provides guidelines for writing final theses at the Faculty of Technical Sciences, University of Novi Sad. At the same time, it serves as a Typst template.		
Accepted by the Scientific Board on, ASB :		
Defended on, DE : 01.01.2025		
Defended Board, DB :	President:	Petar Petrović, Phd., assoc. professor
	Member:	Marko Marković, Phd., asist. professor
	Member:	Menthor's sign
	Member, Mentor:	Milan Segedinac, Phd., full professor



УНИВЕРЗИТЕТ У НОВОМ САДУ • ФАКУЛТЕТ ТЕХНИЧКИХ НАУКА
21000 НОВИ САД, Трг Доситеја Обрадовића 6

ИЗЈАВА О НЕПОСТОЈАЊУ СУКОБА ИНТЕРЕСА

Изјављујем да нисам у сукобу интереса у односу ментор – кандидат и да нисам члан породице (супружник или ванбрачни партнер, родитељ или усвојитељ, дете или усвојеник), повезано лице (крвни сродник ментора/кандидата у правој линији, односно у побочној линији закључно са другим степеном сродства, као ни физичко лице које се према другим основама и околностима може оправдано сматрати интересно повезаним са ментором или кандидатом), односно да нисам зависан/на од ментора/кандидата, да не постоје околности које би могле да утичу на моју непристрасност, нити да стичем било какве користи или погодности за себе или друго лице било позитивним или негативним исходом, као и да немам приватни интерес који утиче, може да утиче или изгледа као да утиче на однос ментор-кандидат.

У Новом Саду, дана _____

Ментор

Кандидат

Садржај

1	Увод	1
2	Теоријске основе	3
2.1	Обрада и репрезентација звука	3
2.2	Обрада и репрезентација текста	5
2.3	Традиционални алгоритми за регресију	7
2.4	Архитектуре дубоког учења (енг. <i>Deep Learning</i> , DL)	9
3	Спецификација захтева	11
3.1	Циљеви и захтеви модела	11
3.2	Евалуација предикција модела	12
3.3	Упоредивање са сличним радовима	14
4	Архитектура система	17
4.1	Скуп података	18
4.2	Претпроцесирање	20
4.3	Алгоритми за екстракцију важних обележја	21
4.4	Регресиони алгоритми машинског учења	27
5	Верификација и валидација	29
6	Закључак	31
	Списак слика	33
	Списак листинга	35
	Списак коришћених скраћеница	37
	Списак коришћених појмова	39
	Биографија	41
	Литература	43

Депресија је поремећај расположења (енг. *mood disorder*) који чини да се особа осећа потонуло под теретом свог постојања. Главни симптом депресије је распаднуто расположење (енг. *decayed mood*), а чести су и напади панике, тежња ка изолацији, ниско самопоуздање и други. Ови симптоми могу постати хронични и тиме отежати особи нормално функционисање у свакодневним активностима [1]. Процењује се да преко 300 милиона људи живи са депресијом, због чега је Светска здравствена организација рангира као највећи узрок инвалидитета у свету [2]. Дијагностификовање депресије започиње састављањем клиничког интервјуа. Доктор затим спроводи интервју са пацијентом. Након тога доктор анализира добијене одговоре. На основу анализе тих одговора доктор даје дијагнозу и одређује терапију. Међутим, овај процес има потешкоће због стигме придружене овој болести, неадекватне обучености доктора и препрека у комуникацији између доктора и пацијента. Ове потешкоће настају јер лекари немају довољно специјализоване обуке, док пацијенти због срама или страха не износе јасно емоционалне симптоме [3].

Истраживања су показала да постоји висок ниво корелације између акустичких и текстуалних карактеристика говора и нивоа депресије особе. Због тога је аутоматизација процене нивоа депресије уз помоћ машинског учења (ML, енг. *Machine Learning*) постала популарна [4], [5]. Овакав алгоритам ML се обучава на аудио записима и транскриптима оцењених клиничких интервјуа између доктора и пацијената. Те оцене додељују доктори по одређеној клиничкој скали.

Овај рад истражује примену ML за дијагнозу депресије на основу акустичких обележја аудио записа и текстуалних обележја њихових транскрипата на *Patient Health Questionnaire* скали са осам питања (PHQ-8). Ова скала је утврђена као валидна мера тежине депресивних поремећаја у великим клиничким студијама. Резултати на овој скали су цели бројеви од нула до 24. Сваки резултат преко девет сматра се обликом депресије [6]. Овакав алгоритам је најкориснији докторима. Они треба да спроведу и сниме клинички интервју са пацијентом. Затим се тај аудио запис и његов транскрипт дају као улаз алгоритму. На крају алгоритам даје сугестију за ниво депресије на PHQ-8 скали. Овако доктори имају додатну информацију за консултацију. На тај начин се ублажава ослањање искључиво на процену лекара, јер алгоритам пружа додатну оцену. Решење је корисно и пацијентима, јер повећава шансу да добију адекватну дијагнозу и терапију.

Глава 2

Теоријске основе

Превођење клиничке дијагностификације депресије у проблем машинског учења (енг. *Machine Learning*, ML) подразумева мапирање клиничке оцене депресије на аудио записе гласова у клиничким интервјуима и текстуалне записе њихових транскрипата [7]. Циљ овог поглавља је представљање теоријских основа неопходних за разумевање решења које је примењено у овом дипломском раду. Како би систем могао ефикасно да предвиди ниво депресије на основу говора и текста, неопходно је разумети како се звук и текст могу репрезентовати у формату погодном за рачунарску обраду, као и које ML алгоритме је могуће применити на таквим подацима.

Ово поглавље је подељено у четири главне целине. У првом делу је објашњена обрада и репрезентација звука, са посебним фокусом на класичне технике попут Мел-фреквенцијских кепстралних коефицијената (MFCC), као и савремене дубоке аудио репрезентације попут Wav2Vec2, HuBERT и WavLM модела. У другом делу су описане технике за обраду и репрезентацију текста, почевши од основног претпроцесирања, преко TF-IDF приступа, до напредних језичких модела базираних на Трансформер архитектури (BERT, RoBERTa, MPNet) и концепта учења без претходних примера (енг. *Zero-shot learning*). У трећем делу су детаљно објашњени традиционални ML алгоритми за регресију, укључујући моделе са регуларизацијом и ансамбл методе. Коначно, у четвртном делу, приказане су DL архитектуре попут вишеслојног перцептрона и конволутивних неуронских мрежа.

2.1 Обрада и репрезентација звука

Звук је у свом изворном облику континуални, аналогни сигнал промене притиска ваздуха. Да би рачунар могао да га обрађује, сигнал се мора дигитализовати процесом одабирања (енг. *sampling*) и квантизације. Брзина одабирања (често 16 kHz у обради говора) одређује колико се пута у секунди мери амплитуда сигнала. Међутим, сирови дигитални аудио записи садрже огромну количину информација од којих многе представљају шуштање, тишину или факторе који нису релевантни за анализу емоционалног стања говорника. Због тога се примењују различите технике за екстракцију карактеристика (енг. *feature extraction*), чији је циљ издвајање најбитнијих акустичких особина сигнала [8].

2.1.1 Мел-фреквенцијски кепстрални коефицијенти (MFCC)

Традиционални приступи у анализи говора често се ослањају на екстракцију Мел-фреквенцијских кепстралних коефицијената (MFCC, енгл. *Mel Frequency Cepstral*

Coefficients). MFCC представљају звук у облику који наглашава фреквенцијске особине важне за људски слух [9]. Људско ухо не перципира промене у фреквенцији линеарно; много је осетљивије на промене у нижим фреквенцијама него у вишим. Мел скала је математичка трансформација која oponaша овај нелинеарни начин перцепције звука, а која се може апроксимирати формулом:

$$m = 2595 \log_{10} \left(1 + \frac{f}{700} \right)$$

где m представља фреквенцију у Мелима, док f представља оригиналну фреквенцију у Херцима (Hz).

Процес израчунавања MFCC карактеристика започиње поделом аудио сигнала на кратке временске прозоре (обично дужине од 20 до 40 милисекунди). Ова подела се врши зато што се говорни сигнал непрекидно мења, али се током веома кратког интервала може сматрати стационарним. На сваки прозор се примењује Брза Фурјеова трансформација (енг. *Fast Fourier Transform*, FFT) како би се добио фреквенцијски спектар сигнала. Добијени спектар се затим пропушта кроз скуп троугаоних филтара (енг. *filter bank*) који су гушће распоређени у нижим фреквенцијама према Мел скали. Након тога се рачуна логаритам енергије у сваком филтру, чиме се симулира перцепција гласности код човека. На крају се примењује инверзна Дискретна косинусна трансформација (енг. *Discrete Cosine Transform*, DCT) како би се добили коначни кепстрални коефицијенти [9]. MFCC се показао као изузетно стабилна репрезентација, јер изоловано приказује карактеристике вокалног тракта говорника, ефикасно одбацујући већи део шума.

2.1.2 Дубоке репрезентације звука (Wav2Vec2, HuBERT, WavLM, Audeering)

Иако је MFCC дуго представљао стандард у обради говора, развој DL-а донео је нове парадигме које не захтевају ручно дефинисање параметара. Уместо тога, модели уче моћне скривене репрезентације директно из сировог аудио сигнала коришћењем само-надгледаног учења (енг. *self-supervised learning*).

Један од најзначајнијих приступа је **Wav2Vec2** [10]. Овај модел се обучава на огромним скуповима неанотираних аудио података тако што покушава да предвиди маскиране (сакривене) делове звука. Архитектура модела састоји се од вишеслојне конволутивне неуронске мреже која издваја локалне карактеристике из сировог таласног облика, након чега следи Трансформер мрежа која гради контекстуалну репрезентацију целог говорног сегмента. Репрезентације добијене на овај начин садрже богато знање о фонетици, интонацији и паралингвистичким карактеристикама гласа, што их чини идеалним за накнадну примену (енг. *fine-tuning*) на специфичним задацима попут детекције депресије.

HuBERT (енг. *Hidden-Unit BERT*) је сличан приступ који користи метод скривених јединица [11]. Уместо предвиђања континуалних аудио вектора као код Wav2Vec2 модела, HuBERT користи алгоритам за кластеризацију (обично *k-means*) над акустичким карактеристикама како би доделио дискретне ознаке сваком кратком сегменту звука. Затим се модел обучава да предвиди ове дискретне ознаке за маскиране регионе користећи Трансформер архитектуру, што резултира веома робусним акустичким репрезентацијама које су мање осетљиве на мање варијације у звуку.

WavLM проширује концепт HuBERT-а увођењем маскирања и симулације шума током само-надгледаног учења [12]. Циљ WavLM модела није само предвиђање говора, већ и издвајање гласа говорника из позадинске буке (познато као задатак одвајања говорника). Због овога, WavLM модел је знатно отпорнији на амбијенталну буку и посебно је погодан за анализу клиничких интервјуа који често нису снимани у идеалним студијским условима.

Поред модела који уче опште репрезентације, постоје и модели који су додатно фино подешени (енг. *fine-tuned*) на специфичним скуповима података за препознавање емоција. Један такав пример је **Audeering** модел, који се базира на Wav2Vec2 архитектури, али је накнадно трениран на скуповима говорних емоција. Коришћењем оваквих модела добијају се карактеристике које директно описују емоционално стање говорника, што их чини веома ефикасним за детекцију депресије [13].

2.2 Обрада и репрезентација текста

Текст је по својој природи неструктуриран и дискретан податак. Да би ML алгоритми могли да га анализирају, текстуални транскрипти клиничких интервјуа се морају претворити у нумеричку форму. Начин на који се текст претпроцесира и представља има кључан утицај на способност модела да разуме семантику, синтаксу и контекст изговорених речи пацијента.

2.2.1 Претпроцесирање и нормализација

Пре саме векторизације, текст обично пролази кроз неколико фаза нормализације. Први корак је **токенизација**, процес дељења текста на мање јединице, попут речи или подречи (енг. *subwords*). Затим се често примењује претварање свих слова у мала слова и уклањање интерпункцијских знакова како би се смањила димензионалност простора речи.

Да би се смањила граматичка варијација речи (нпр. “радити”, “радим”, “радио”), користи се **лематизација** (енг. *lemmatization*). Лематизација своди сваку реч на њен основни, речнички облик (лему), водећи рачуна о контексту у реченици. Додатно, често се уклањају стоп-речи (енг. *stop words*), што су уобичајене речи попут предлога и везника (“у”, “на”, “или”) које се појављују веома често, али носе мало информација о емоционалном или семантичком стању пацијента.

2.2.2 Традиционалне репрезентације: TF-IDF

Један од најпознатијих класичних приступа векторизацији текста је TF-IDF (енг. *Term Frequency-Inverse Document Frequency*). Ова метода процењује важност појединачне речи у оквиру једног транскрипта у односу на цео скуп транскрипата свих пацијената [14]. Овај приступ текст посматра као “врећу речи” (енг. *Bag of Words*), занемарујући граматику и редослед речи, већ се фокусира искључиво на то које су речи присутне и колико често.

Формула TF-IDF састоји се из две компоненте. *Term Frequency* (TF) мери колико се пута одређена реч појављује у документу. Што се реч чешће појављује у транскрипту једног пацијента, њен значај расте. Да би се спречило да речи које су глобално честе (уколико нису уклоњене као стоп-речи) доминирају вектором, уводи се *Inverse Document Frequency* (IDF) компонента, која логаритамски кажњава речи које су присутне у великом броју докумената. На тај начин, TF-IDF високу вредност додељује само оним речима које су специфичне за посматрани транскрипт, чиме ефикасно издваја кључне појмове [14].

Математички, вредност TF-IDF за реч t у транскрипту d из скупа свих транскрипата D се рачуна као:

$$\text{TF-IDF}(t, d, D) = \text{TF}(t, d) \times \text{IDF}(t, D)$$

где је $\text{TF}(t, d)$ број појављивања речи t у транскрипту d , док се IDF компонента рачуна на следећи начин:

$$\text{IDF}(t, D) = \log \left(\frac{N}{|\{d \in D : t \in d\}|} \right)$$

при чему N представља укупан број транскрипата у скупу D , а $|\{d \in D : t \in d\}|$ представља број транскрипата у којима се појављује реч t .

2.2.3 Угнежђивање речи и Трансформер модели

Да би се превазишла ограничења традиционалних метода које не разумеју сродност међу речима, развијене су технике за густо угнежђивање речи (енг. *Word Embeddings*), попут Word2Vec и GloVe алгоритама. Ови приступи представљају сваку реч као густ вектор у вишедимензионалном простору у ком су семантички сличне речи позициониране близу једна другој. Међутим, њихов недостатак је што свакој речи додељују само један фиксиран вектор, без обзира на контекст у којем се реч налази (проблем полисемије).

Револуцију у обради природног језика (енг. *Natural Language Processing*, NLP) донела је архитектура Трансформер [15]. За разлику од ранијих модела, Трансформер се ослања искључиво на механизам “пажње” (енг. *Self-Attention*). Овај механизам омогу-

ћава моделу да током обраде једне речи процени и интегрише информације из свих осталих речи у реченици, рачунајући “тежине пажње” које говоре колико свака друга реч утиче на тренутну реч, према математичкој формулацији:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

где Q (упит, енгл. *Query*), K (кључ, енгл. *Key*) и V (вредност, енгл. *Value*) представљају матрице добијене линеарном трансформацијом улазних вектора, док d_k представља димензију кључа која служи као фактор скалирања. Резултат су контекстуализована угнежђивања: иста реч добија другачији нумерички вектор у зависности од контекста.

На Трансформер архитектури засновани су многи савремени језички модели:

- **BERT** (енгл. *Bidirectional Encoder Representations from Transformers*) чита текст двосмерно и учи да предвиди маскиране речи у реченици, стичући дубоко разумевање језика [16].
- **DistilRoBERTa** (посебно варијанте фино подешене за детекцију емоција попут *Emotion English DistilRoBERTa*) нуди компактнију и ефикаснију архитектуру која директно мапира текст на емоционална стања, што је корисно за анализу сентимента у интервјуима [17].
- **RoBERTa** (енгл. *Robustly Optimized BERT Pretraining Approach*) представља унапређену верзију BERT-а која се обучава дуже, на већем скупу података и са динамичким маскирањем, чиме се постижу значајно боље перформансе [18].
- **MPNet** (енгл. *Masked and Permuted Pre-training*) комбинује предности модела који маскирају текст и модела који пермутују редослед речи током тренирања, постижући изузетну прецизност у задацима где је потребно разумети текст у целини [19].

2.2.4 Велики језички модели и Zero-shot учење

Са појавом великих језичких модела (енгл. *Large Language Models*, LLM) са милијардама параметара (попут T5 фамилије, нпр. FLAN-T5) [20], постао је популаран приступ познат као учење без претходних примера или Zero-shot Prompting [21]. За разлику од традиционалног финог подешавања где се модел обучава на скупу транскрипата пацијената како би предвидео PHQ-8 скор, LLM се може директно упитати путем природног језика (нпр. “Анализирај овај транскрипт и процени ниво депресије на скали од 0 до 24”). Иако су ови модели изузетно моћни и генерални, њихова способност да прецизно одговоре на специфичне клиничке скале често зависи од квалитета упутства (енгл. *prompt*).

2.3 Традиционални алгоритми за регресију

Након што су звук и текст претворени у нумеричке векторе (било путем TF-IDF матрица, MFCC-а или дубоких репрезентација), следећи корак је примена ML алгори-

тама. Пошто је циљна променљива нумеричка вредност (PHQ-8 скор од 0 до 24), овај задатак се у ML-у формулише као проблем регресије. Класични (традиционални) ML алгоритми су и даље веома популарни јер нуде високу интерпретабилност, захтевају мање рачунарских ресурса од дубоких неуронских мрежа и често показују одличне перформансе на мањим скуповима података какви су уобичајени у медицинском домену.

2.3.1 Линеарни модели са регуларизацијом

Обична линеарна регресија покушава да пронађе линеарну комбинацију улазних карактеристика која најбоље описује циљну променљиву. Међутим, када се ради са подацима високе димензионалности (попут TF-IDF вектора који могу имати хиљаде димензија), обична линеарна регресија је веома склона преприлагођавању (енг. *overfitting*) — модел буквално “напамент научи” податке за тренирање, али веома лоше ради на новим пацијентима.

Да би се овај проблем решио, користе се линеарни модели са регуларизацијом који уводе казни фактор за претерано велике тежине (коэффициенте) модела:

- **Grebenasta (Ridge) регресија** уводи L_2 регуларизацију [22]. Она кажњава квадрат вредности коэффицијената, што приморава модел да задржи коэффицијенте малим и равномерно распоређеним. Функција грешке коју модел минимизује је облика $J(w) = \text{MSE}(w) + \alpha \sum_{j=1}^p w_j^2$, где је α параметар који контролише јачину регуларизације. Ово је посебно корисно када постоји много међусобно повезаних (корелираних) карактеристика.
- **Еластична мрежа (ElasticNet)** комбинује предности две врсте регуларизације: L_1 (која форсира да неки коэффицијенти постану тачно нула, чиме се врши селекција карактеристика) и L_2 (која стабилизује модел) [23]. Функција грешке облика $J(w) = \text{MSE}(w) + \alpha \rho \sum_{j=1}^p |w_j| + \alpha \frac{1-\rho}{2} \sum_{j=1}^p w_j^2$ омогућава балансирање ове две казне преко параметра ρ . Ова комбинација је идеална када је потребно одабрати подскуп најважнијих речи или аудио карактеристика.
- **Bajesova (Bayesian Ridge) регресија** приступа проблему из угла вероватноће [24]. Уместо да тражи једну фиксну вредност за сваки коэффициент, она модел третира као дистрибуцију вероватноће. То јој омогућава да аутоматски прилагоди меру регуларизације из самих података, чинећи је веома стабилном и отпорном на шум.

2.3.2 Модели базирани на ансамблима и стаблима

Модели базирани на стаблима одлучивања (енг. *Decision Trees*) деле простор карактеристика на мање регионе путем низа једноставних “да/не” правила. Међутим, једно стабло је често непрецизно и нестабилно. Због тога се користе технике укомбиновања више модела у ансамбл.

- **Случајна шума (Random Forest)** гради велики број независних стабала одлучивања током тренирања, при чему свако стабло користи насумичан подскуп података и карактеристика [25]. Коначно предвиђање модела се добија усредњавањем предвиђања свих стабала. Ово драстично смањује варијансу и спречава преприлагођавање, чинећи овај алгоритам једним од најпоузданијих за мање скупове података.
- **Грађијентно појачавање (Gradient Boosting)** је другачији приступ ансамблу где се стабла граде секвенцијално [26]. Свако ново стабло покушава да исправи грешке (резидуале) које су направила сва претходна стабла заједно. Због своје способности да науче веома сложене нелинеарне везе, ови модели често постижу најбоље резултате међу традиционалним ML алгоритмима.

2.3.3 Регресија потпорних вектора (SVR)

Регресија потпорних вектора (SVR, енгл. *Support Vector Regression*) је моћан алгоритам који дефинише толеранцијску зону, односно маргину (која се назива ε -цев), око регресионе линије [27]. Модел не кажњава грешке предвиђања које упадну унутар ове цеви, чиме се фокусира само на податке који значајније одступају од тренда (познате као потпорни вектори).

Кључна снага SVR модела лежи у коришћењу тзв. “кERNEL трика” (енгл. *kernel trick*). KERNEL функција (попут радијалне базисне функције, RBF) омогућава имплицитно мапирање података у простор виших димензија, где постаје могуће пронаћи линеарну везу, чак и када су подаци у оригиналном простору изразито нелинеарни. Због ових својстава, SVR се често користи за предвиђање депресије на основу акустичких обележја попут MFCC-а.

2.4 Архитектуре дубоког учења (енгл. *Deep Learning, DL*)

Док класични алгоритми захтевају претходну обраду података у векторе фиксних димензија (и често ручни одабир најбољих карактеристика), DL архитектуре су способне да аутоматски екстрахују хијерархијске репрезентације из сложених и секвенцијалних података. Ово их чини незаменљивим за анализу аудио спектрограма или секвенци речи.

2.4.1 Вишеслојни перцептрон (MLP)

Вишеслојни перцептрон (енгл. *Multi-Layer Perceptron, MLP*) представља најједноставнију архитектуру дубоке неуронске мреже. Састоји се од улазног слоја, једног или више скривених слојева и излазног слоја. Сваки слој се састоји од великог броја неурона који су потпуно повезани са неуронима претходног слоја. Излаз сваког скривеног слоја рачуна се као:

$$h = \sigma(Wx + b)$$

где је x вектор улаза у слој, W матрица тежина, b вектор пристрасности (енг. *bias*), а σ нелинеарна активациона функција (као што су ReLU или Tanh). Коришћењем оваквих нелинеарних функција, MLP може моделовати веома комплексне математичке функције. Овај модел представља основу DL-а и користи се као стандардни завршни регресиони модул након екстракције карактеристика.

2.4.2 Конволутивне неуронске мреже (CNN)

Конволутивне неуронске мреже (CNN) су оригинално развијене за обраду слика, али су показале изузетне перформансе и у анализи звука и текста [28]. CNN користи конволутивне слојеве који функционишу као филтри (кernels) који клизе преко улазних података.

- У обради звука (2D CNN), улаз је често спектрограм (нпр. MFCC визуелизација). Филтри детектују локалне обрасце попут наглих промена у фреквенцијама или енергији сигнала. Како се пролази кроз дубље слојеве мреже, модел комбинује ове једноставне обрасце у сложеније апстракције.
- У обради текста (1D CNN), филтри клизе преко секвенце речи (где је свака реч представљена вектором). Ово омогућава детекцију локалних обрасца попут n -грама (комбинација од неколико узастопних речи) које имају снажан семантички или емоционални утицај [29].

Глава 3

Спецификација захтева

У овом поглављу су дефинисани захтеви и циљеви које развијени модели ML треба да испуне како би успешно предвиђали ниво депресије на основу клиничких интервјуа. Ово се постиже кроз јасно дефинисање захтеваних карактеристика ових модела, као и метрика помоћу којих ће се евалуирати њихова успешност. Додатно, дато је поређење са радовима са сличним тематикама из ове области, како би се очекивања и циљеви поставили у реалан контекст.

Важно је истаћи да је у оквиру овог рада испробано доста различитих модела. Системски развој, испробавање и упоредна анализа великог броја модела представљају један од кључних циљева овог рада, како би се истражили различити приступ.

3.1 Циљеви и захтеви модела

Примарни циљ сваког развијеног модела у овом раду је пружање помоћи докторима и клиничким радницима приликом дијагностификовања депресије. У традиционалној психијатријској пракси, дијагноза се у некој мери ослања на субјективну процену лекара која се формира током интервјуа са пацијентом [7]. Употребом ML, тежи се увођењу потпуно објективне, квантитативне мере.

Процес коришћења оваквих модела у пракси изгледао би овако: након што доктор спроведе и сними стандардизовани клинички интервју са пацијентом, аудио запис тог интервјуа, заједно са његовим транскриптом, представља улаз за модел. Излаз који модел генерише је предвиђена вредност нивоа депресије на PHQ-8 скали (вредност од 0 до 24). Овим приступом доктор би добио сугестију као додатни параметар током доношења коначне дијагнозе. Развијени модели нису дизајнирани да замене доктора, већ да се истражи могућност пружања помоћи у доношењу одлука.

Из описа коришћења и домена проблема могу се извући следећи кључни захтеви које ови модели треба да задовоље:

- Предвиђање нумеричке оцене депресије блиске реалној оцени депресије:** Модели треба да мапирају акустичке карактеристике гласа (попут интонације, фреквенције и енергије) и текстуалне особине говора (попут семантике, кључних изговорених речи и сентимента) у континуалну нумеричку вредност која одговара валидној PHQ-8 вредности. Ова вредност треба да буде што ближа правој вредности за пацијента, као што би била оцена најбољег доктора. Више о томе како се ово евалуира је дато у наставку у секцији Евалуација модела.

2. **Отпорност на позадинску буку и несавршене транскрипте:** С обзиром на то да се клинички интервјуи не снимају увек у идеалним студијским условима, модели морају бити довољно робусни да доносе закључке упркос благим акустичким сметњама или ретким грешкама у улазном транскрипту интервјуа [30]. Ово је испуњено ако су предикције добре и за неоптималне улазе.
3. **Заштита приватности пацијената:** Обрада података мора бити дизајнирана тако да ограничи излагање осетљивих медицинских информација. Један од приступа је ограничавање приступа подацима на минимални обим неопходан за њихову обраду, као и примена техника попут псеудонимизације и намерног замућивања података [31].
4. **Рачунарска ефикасност:** Упркос коришћењу сложених модела, предикције модела за једног пацијента морају се обавити у разумном времену на обичном рачунару. Ово је важно за примену у реалним болничким условима.
5. **Интерпретабилност модела:** Како би медицинско особље боље разумело зашто је модел предложио одређену PHQ-8 вредност, добро је да модел омогући анализу и интерпретацију тога на основу којих карактеристика је донео одлуку (нпр. издвајање кључних речи из транскрипта). Додатно, након тренинга модела на великом скупу података, корисно је интерпретирати тај модел и видети које карактеристике уопштено чешће означавају више нивое депресије, а које карактеристике уопштено означавају ниже нивое депресије.

3.2 Евалуација предикција модела

Да би се објективно проценило колико развијени модели успешно предвиђају PHQ-8 вредности, неопходно је дефинисати метрике за њихову евалуацију. Критеријум успеха представља разлика између предвиђене оцене коју генерише одређени модел и стварне оцене коју је доделио стручњак. Циљ је да предвиђене оцене буду што ближе стварној оцени коју је доделио стручњак. За евалуацију перформанси одабране су следеће три кључне метрике:

3.2.1 Средња апсолутна грешка (MAE)

Средња апсолутна грешка (енг. *Mean Absolute Error*, MAE) показује просечно апсолутно одступање предвиђене PHQ-8 оцене од стварне оцене. Она представља директну, лако интерпретабилну меру просечне грешке у предвиђању модела. Што је MAE мањи, то су предвиђања модела у просеку ближа стварним вредностима на PHQ-8 скали [32].

Математички, MAE се дефинише као:

$$\text{MAE} = \frac{1}{N} \sum_{i=1}^N |y_i - \hat{y}_i|$$

где је N укупан број узорака (пацијената), y_i представља стварну оцену (коју је доделио стручњак) на PHQ-8 скали за i -тог пацијента, док $\hat{y}_i$ представља оцену коју је модел предвидео. Како PHQ-8 скала има распон од 0 до 24, MAE вредност од, на пример, 6.0, значила би да модел у просеку промаши стварну оцену за 6 поена.

3.2.2 Коренована средња квадратна грешка (RMSE)

Коренована средња квадратна грешка (енг. *Root Mean Square Error*, RMSE) се израчунава као квадратни корен из просека квадрата грешака. За разлику од MAE, који свим грешкама даје једнаку тежину, RMSE због квадрирања додатно наглашава веће грешке [32]. Ова метрика је корисна јер открива да ли модел често прави велика одступања (нпр. ако модел предвиди здраву особу као тешко депресивну), што је у медицинском домену веома непожељно понашање.

Формула за RMSE дата је једначином:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2}$$

Иако RMSE генерално даје веће вредности од MAE за исти скуп података, његов значај лежи у оштром кажњавању великих грешака. Циљ модела је да оптимизује (минимизује) обе ове вредности истовремено.

3.2.3 Пирсонов коефицијент корелације (ρ)

Пирсонов коефицијент корелације (ρ) мери степен линеарне повезаности између предвиђених оцена и стварних оцена пацијената [33]. Вредност коефицијента се креће у интервалу од -1 до 1 . Вредност ближа броју 1 указује на снажну позитивну корелацију (када стварна оцена расте, и предвиђена оцена расте), док вредности близу 0 указују на непостојање линеарне везе.

Рачуна се према следећој формули:

$$\rho = \frac{\sum_{i=1}^N (y_i - \bar{y})(\hat{y}_i - \bar{\hat{y}})}{\sqrt{\sum_{i=1}^N (y_i - \bar{y})^2 \sum_{i=1}^N (\hat{y}_i - \bar{\hat{y}})^2}}$$

где $\bar{y}$ и $\bar{\hat{y}}$ представљају средње вредности стварних и предвиђених оцена, редом.

За разлику од MAE и RMSE који мере само апсолутну величину грешке, Пирсонов коефицијент показује да ли модел успешно прати тренд кретања података. На пример, модел који доследно предвиђа за 3 поена мање од стварне вредности имаће значајну MAE грешку, али ће и даље имати висок Пирсонов коефицијент јер успешно разликује блаже од тежих облика депресије. Ове три метрике заједно чине свеобухватан оквир за

анализу тога да ли је модел научио да смислено предвиђа вредности и колико просечно греши.

3.3 Упоредивање са сличним радовима

Квалитетно предвиђање нивоа депресије на основу говора и текста представља активно поље истраживања у областима вештачке интелигенције и психијатрије [7]. Током протекле деценије, различити истраживачки тимови су приступили овом проблему дефинишући своје циљеве. Како би се циљеви и резултати у оквиру овог рада боље разумели, корисно је упоредити његове циљеве са репрезентативним радовима из ове области.

У традиционалним приступима, попут истраживања које су спровели Alhanai et al. [34], фокус је стављен на моделовање секвенци интервјуа коришћењем и аудио и текстуалних података. Њихов циљ био је развој комплексног модела који би узимао у обзир временску динамику целог разговора. Испробавали су и регресију и класификацију. Што се тиче регресије, тест скупу података су постигли следеће резултате: MAE вредност од око 5.18 (само текстуални модел) и 5.13 (само аудио модел), RMSE вредност од око 6.38 (само текстуални модел) и 6.50 (само аудио модел). Напредак у овој области карактерише прелазак са класичних алгоритама на дубоке неуронске мреже, као што је приказано у истраживању Pan et al. [4], где су конволутивне неуронске мреже (CNN) искоришћене за екстракцију просторних и временских образаца директно из звука. Њихов приступ је показао предност у аутоматској екстракцији карактеристика, али по цену знатно мање интерпретабилности.

Са друге стране, недавна истраживања све више испитују употребу лингвистичких карактеристика за предвиђање депресије. Alhussen [5], на пример, представља хијерархијски Transformer модел за анализу лингвистичких карактеристика повезаних са депресивним стањима. Предложени модел комбинује различите нивое језичке анализе, укључујући лексичке, синтаксичке и семантичке карактеристике, са хијерархијским механизмима пажње, показујући потенцијал дубоких модела заснованих на језичким карактеристикама за предвиђање депресије.

У поређењу са овим радовима, специфични циљеви истраживања у овом раду позиционирани су на следећи начин:

1. **Модел засновани на аудио записима и модели засновани на транскриптима, искључиво уз регресију:** Модел су или засновани искључиво на аудио записима или искључиво на транскриптима. Такође, није испитивана класификација, већ само регресија.
2. **Свеобухватно поређење великог броја модела:** У оквиру овог рада развијен је и тестиран велики број различитих модела, како за текстуалну, тако и за акустичку анализу. Циљ је да се системски упореде традиционални алгоритми машинског

учења са модерним приступом заснованим на Трансформерима, како би се идентификовале добре комбинације за предвиђање депресије.

3. **Баланс између перформанси и комплексности:** С обзиром да су сви модели тренирани и извршавани на стандардном лаптопу, није било могуће развити претерано комплексне и напредне алгоритме због хардверских ограничења. Због тога, циљ је постизање конкурентне прецизности (MAE, RMSE и Пирсонов коефицијент корелације у нивоу или бољи од споменутих радова) уз избегавање непотребне комплексности модела. Испитује се да ли једноставнији алгоритми, подржани дубоким екстракторима особина попут RoBERTa-е или WavLM-а, могу надмашити тешке дубоке алгоритме у погледу ефикасности, што је кључно за примену у пракси.
4. **Упоредна анализа репрезентација и интерпретабилност:** Поред ригорозног поређења традиционалних приступа са модерним само-надгледаним моделима, важан циљ је и интерпретација резултата. Тежи се разумевању како различити модели доносе одлуке и које конкретне карактеристике највише доприносе предвиђању нивоа депресије.


Кроз јасно дефинисање ових захтева и циљева, обезбеђен је чврст оквир у којем ће се дизајнирати, имплементирати и на крају евалуирати велики број модела описаних у наредном поглављу.

Глава 4

Архитектура система

У овом поглављу приказан је начин на који су изграђени финални модели за предвиђање нивоа депресије, односно како су алгоритми описани у теоријским основама комбиновани и примењени у пракси како би се добили најбољи резултати. Основни улаз у било који модел чине аудио записи клиничких интервјуа или њихови текстуални транскрипти, док је очекивани излаз модела једна нумеричка вредност која представља процењену оцену на PHQ-8 скали (од 0 до 24).

На високом нивоу апстракције, архитектура решења се састоји из две независне гране: једне за анализу акустичких карактеристика и друге за анализу текстуалних транскрипата. Обе гране започињу фазом учења и претпроцесирања улаза из скупа података, након чега се врши екстракција обележја (било традиционалним методама попут MFCC-а и TF-IDF-а, или помоћу дубоког учења и Трансформера). Скуп података и претпроцесирање су исти за сваки модел, а алгоритам за екстракцију обележја је оно што је посебно за сваки развијен модел. Добијена обележја се затим прослеђују моделима машинског учења или неуронским мрежама који на основу тих обележја врше финалну регресију и враћају предвиђену PHQ-8 оцену. У циљу проналаска најбољих регресионих алгоритама машинског учења и њихових хиперпараметара, коришћен је RandomizedSearchCV. За званичан пример модела одабрен је онај регресиони алгоритам и његови хиперпараметри који имају најбољу комбинацију MAE, RMSE и Пирсоновог коефицијента корелације. Слика 1 илуструје ток података у систему.



Слика 1: Ток података на високом нивоу

Сходно томе, ово поглавље биће подељено на скуп података, заједничко претпроце-сирање, алгоритми за екстракцију важних обележја и алгоритме машинског учења за регресију.

Сви описани алгоритми имплементирани су у програмском језику Пајтон (енг. *Python*), коришћењем стандардних библиотека за обраду података и машинско учење. За рад са звуком примарно је коришћена библиотека *librosa*, док је за текст коришћен *nlTK*. Традиционални модели машинског учења имплементирани су помоћу *scikit-learn* библиотеке, док су архитектуре дубоког учења изграђене у *PyTorch* оквиру. За екстракцију напредних текстуалних и аудио репрезентација коришћена је библиотека *transformers* компаније *Hugging Face*, као и *sentence-transformers*.


4.1 Скуп података

Скуп података (енг. *dataset*) је преузет са веб-сајта [Универзитета Јужне Калифорније](#). Доступан је у академске сврхе на посебан захтев (свака комерцијална употреба је строго забрањена) [35], [36]. Садржи 275 клиничких интервјуа и њихове аудио записе, транскрипте, и PHQ-8 оцене.


Главни изазов у вези са овим скупом података је то што садржи мали број инстанци. Поврх тога, појединим инстанцама недостају аудио записи или транскрипти и због тога су те инстанце одбачене. Као последица тога, укупан број доступних података је

низак. Ово отежава поуздано тренирање модела, јер моћ ML-а лежи у препознавању шаблона у подацима [37]. Додатно, и аудио снимци и транскрипти нису савршеног квалитета. Аудио записи садрже шум, док транскрипт понекад има нетачно извучене речи. Због тога је највећи изазов током израде овог рада био проналажење приступа који омогућава ефикасну обраду и искоришћавање оваквог скупа података.

Детаљнијом анализом скупа података можемо приметити одређене шаблоне у скупу података. На слици 2 је приказан хистограм дистрибуције PHQ-8 оцена на тренинг и валидационом спојеном скупу. Може се закључити да значајно више инстанци има ниже PHQ-8 оцене, те да се мора учинити нешто како модели не би имали пристрасну тенденцију да предвиђају ниже оцене. Просечна оцена је 6.52, а медијана је 5.0. Просечна дужина аудио записа је око 16 минута, а медијана је око 15 минута. Ово указује на то да ће тренирање модела над овим аудио записима бити изузетно хардверски захтевно. Што се тиче транскрипата, дистрибуција броја речи по транскрипту интервјуа дата је на слици 3.



Слика 2: Хистограм дистрибуције PHQ-8 оцена на тренинг и валидационом спојеном скупу



Слика 3: Дистрибуција броја речи по транскрипту интервјуа

Сам скуп података подељен је на тренинг (енг. *train*), валидациони (енг. *validation*) и тест скуп. Тренинг скуп обухвата 163 податка (од тога 6 нема аудио запис и 7 нема транскрипт), а валидациони и тест по 56 (у тест скупу 2 инстанце нема аудио запис и 3 нема транскрипт). Тренинг и валидациони скуп су спојени и корићени као један скуп, углавном за тренинг модела кроз крос валидацију. Тест скуп служи за финалну, непристрасну оцену квалитета модела. Сваки податак из скупа података прослеђује се даље фази претпроцесирања.

4.2 Претпроцесирање

4.2.1 Акустички модели

Претпроцесирање за акустичке моделе је процес трансформације аудио записа у репрезентацију погодну за учење модела ML. Ово се ради са циљем унапређења ефикасности модела применом различитих техника обраде [8]. За акустичке моделе, претпроцесирање аудио записа врши се коришћењем библиотеке *librosa*. Први корак подразумева учитавање аудио датотеке при чему се сигнал конвертује у један канал (моно) и узоркује на фреквенцији од 16 kHz. Ово је стандард за већину модела за обраду говора, а уједно и неопходан корак јер се у оригиналним подацима могу наћи вредности које одступају у зависности од коришћеног уређаја за снимање.

Следећи важан корак је нормализација аудио сигнала. Сваки сигнал се дели његовом максималном апсолутном вредношћу (уз додавање изузетно мале вредности како би се избегло дељење нулом), чиме се амплитуде свих узорака свде на опсег од -1 до 1 . Овај корак је кључан како би се поништио утицај различитих нивоа гласности приликом снимања и омогућила стабилнија екстракција карактеристика. Након нормализације, с обзиром на то да су аудио записи варијабилне дужине, а модели ML углавном захтевају улазе фиксних димензија, претпроцесирани сигнал дели се на мање временске прозоре (енг. *windows*) фиксне дужине, најчешће уз одређено преклапање. Овај поступак решава проблем различите дужине интервјуа и посебан је за сваки модел, те ће бити посебно наглашен и у екстракцији обележја. Овакав сигнал биће улаз за алгоритме за екстракцију важних обележја.

Такође, разматрана је и могућност уклањања гласа интервјуера из аудио записа помоћу доступних датотека са транскриптим. Међутим, експериментално је утврђено да уклањање интервјуера доводи до лошијих перформанси модела. Разлог за то је вероватно губитак природног тока разговора и контекста који може бити значајан, због чега је одлучено да се за даљу анализу задржи целокупан аудио запис са оба говорника.

4.2.2 Текстуални модели

Када су у питању текстуални модели, основни подаци су доступни у виду CSV датотека где сваки ред представља једну изговорену реченицу или фразу. Током учитавања

података, издваја се искључиво колона која садржи текст (колона Text). Циљ претпроцесирања овде је претворити сав тај текст у улаз погодан за моделе ML.

Сви редови који не садрже текст се уклањају како би се спречиле грешке у даљој обради. Након тога, све издвојене и очишћене реченице једног интервјуа се спајају у један непрекидан низ речи. Опционо, у зависности од конкретног модела, сав текст се претвара у мала слова ради уједначавања.

С обзиром на то да интервјуи могу бити веома дуги, а напредни језички модели (попут Трансформера) имају ограничење у дужини улаза, текст се за неке моделе даље дели на мање сегменте (енг. *chunks*). Ова подела се врши тако што се дефинише фиксиран број речи по сегменту, уз одређено преклапање (енг. *overlap*) између суседних сегмената како би се сачувао контекст на прелазима између њих.

4.3 Алгоритми за екстракцију важних обележја

Алгоритми за екстракцију важних обележја служе да претворе сирове (енг. *raw*) податке у облик погодан за моделе ML. Ово значи да ће улаз постати компактан, читљив и јасан моделима ML. Ови алгоритми одабрани су тако да се покрију традиционални, једноставни алгоритми и неки напредни, популарни, али не претерано хардверски захтевни алгоритми DL. Код напредних алгоритама циљ је био испробати основне верзије, као и неке специјалне верзије, попут Трансформера претренираних за препознавање осећања. Хиперпараметри алгоритама за екстракцију важних обележја добијени су испробавањем различитих варијанти и на крају су задржани они са најбољим резултати кроз крос валидацију.

4.3.1 Акустички модели

Овај модул система фокусира се искључиво на анализу аудио записа клиничких интервјуа. У оквиру овог модула испробано је неколико различитих приступа, почевши од традиционалних метода машинског учења, преко конволутивних неуронских мрежа, до употребе напредних аудио Трансформер модела.

4.3.1.1 Традиционални алгоритми машинског учења

Овај приступ представља основну (енг. *baseline*) методу за предвиђање депресије из звука. Претпроцесирани аудио записи подељени су на фиксне временске прозоре дужине 30 секунди. Из сваког прозора се екстрахује 40 MFCC. Затим се за сваки од тих прозора рачунају се статистичке мере: средња вредност, стандардна девијација, минимум и максимум, како за саме MFCC коефицијенте, тако и за њихове прве и друге изводе (делта и делта-делта карактеристике). Ове статистике се спајају у један вектор за сваког пацијента и прослеђују регресионим алгоритмима како би се добила финална R²-8 оцена.

4.3.1.2 Конволутивне неуронске мреже (CNN)

С обзиром на то да MFCC репрезентације звука могу да се посматрају као дводимензионалне слике (спектрограми), имплементирана је 2D CNN архитектура. Претпроцесирани аудио сигнал подељен је на краће прозоре од 10 секунди (са преклапањем од 5 секунди) из којих је извучено 40 MFCC коефицијената уз њихове делта и делта-делта изводе, чиме је формирана улазна матрица са три канала (слично RGB сликама). Дизајнирана је CNNRegressor мрежа која се састоји од три конволутивна блока. Сваки блок садржи конволутивни слој (са кернелом величине 3×3), групну нормализацију (енг. *GroupNorm*) ради стабилизације тренинга, ReLU активациону функцију и слој за сажимање (енг. *MaxPool2d*).

Након проласка кроз конволутивне слојеве, примењује се адаптивно усредњавајуће сажимање (енг. *AdaptiveAvgPool2d*) које излаз сваког прозора своди на раван вектор. Како би се спојили сви временски прозори једног пацијента у јединствену репрезентацију, рачунају се средња вредност и стандардна девијација извучених обележја дуж свих прозора. Ове две статистике се конкатенирају формирајући финални вектор дужине 96. Над овим вектором примењује се Dropout регуларизација са вероватноћом 0.4, а затим се он прослеђује потпуно повезаном линеарном слоју (енг. *Fully Connected Layer*) који даје финални предвиђени PHQ-8 скор. Овај модел представља приступ дубоког учења с краја на крај (енг. *end-to-end*) и не користи традиционалне регресионе алгоритме на излазу. Због различитог броја временских прозора по аудио запису, модел је трениран са величином серије (енг. *batch size*) 1.

Модел је оптимизован коришћењем Адам (енг. *Adam*) оптимизатора са брзином учења (енг. *learning rate*) 0.001 и L_2 регуларизацијом (енг. *weight decay*) 10^{-5} . Имплементиран је механизам за аутоматско смањење брзине учења (*ReduceLRonPlateau*) који је полови када се губитак не смањује кроз 2 узастопне епохе. Како би се спречила појава експлодирајућих градијената (енг. *exploding gradients*), примењено је клиповање градијената на максималну норму 5.0. Тренинг је трајао 20 епоха, уз специфичну прилагођену функцију губитка која комбинује средњу апсолутну грешку (MAE) и Пирсонов коефицијент корелације (ρ), формулисана као $0.7 \cdot \text{MAE} + 0.3 \cdot (1 - \rho)$. Ова функција истовремено кажњава нетачна предвиђања и подстиче модел да прати тренд стварних оцена.

4.3.1.3 Екстракција дубоких аудио репрезентација и машинско учење

Како би се искористили већ истренирани јаки модели дубоког учења за извлачење важних карактеристика говора, тестирана су четири различита преттренирана аудио Трансформер модела чија су излазна обележја (енг. *embeddings*) коришћена као улаз за традиционалне ML регресоре. Та четири модела су:

- **wav2vec2:** Користи facebook/wav2vec2-base-960h. Одабран као општи, основни модел.

- **hubert:** Користи facebook/hubert-base-ls960. Одабран као алтернативни основни модел, због специфичног начина тренирања.
- **wavlm:** Користи microsoft/wavlm-base-plus. Одабран као напреднији и робуснији основни модел, прати и ко кад прича.
- **audeering:** Користи модел компаније Audeering фино подешен за препознавање емоција (audeering/wav2vec2-large-robust-12-ft-emotion-msp-dim). Одабран баш због те лепе особине да добро препознаје емоције.

Сваки од тих модела се користи на исти начин. Претходно претпроцесирани звучни сигнал се дели на прозоре дужине 5 секунди, са померајем од 3 секунде. За сваки прозор, Трансформер модел генерише секвенцу излазних скривених стања (енг. *hidden states*). Како би се добила јединствена репрезентација за појединачни прозор, рачунају се средња вредност и стандардна девијација ових стања дуж временске осе, након чега се оне конкатенирају у један вектор. На крају, сви овако добијени вектори прозора једног пацијента се додатно агрегирају рачунањем глобалне средње вредности и стандардне девијације кроз све прозоре. Спајањем ових глобалних статистика формира се финални густ вектор који репрезентује комплетан аудио запис, и он се прослеђује даље алгоритмима ML за предвиђање финалног скорa.

Неопходност овакве агрегације, односно дељења записа на прозоре уместо пропуштања целог интервјуа кроз модел одједном, произилази из ограничења Трансформер архитектуре. Временска и меморијска сложеност механизма пажње (енг. *Self-Attention*) расте квадратно са повећањем дужине улазне секвенце. Пошто су клинички интервјуи изузетно дуги (у просеку 16 минута), њихово процесирање у једном пролазу би захтевало огромну количину радне меморије, што значајно превазилази могућности стандардног хардвера. Иако извлачење статистика (средње вредности и стандардне девијације) успева да задржи значајан део информација, овај приступ агрегацији и даље представља одређену ману. Пре свега, губе се дугорочне зависности и временски контекст разговора. Додатно, оваквим приступом се сваком временском прозору додељује једнака тежина (важност), што је често субоптимално. Пацијент можда испољава јасне вокалне знакове депресије само у појединим деловима интервјуа, док је остатак разговора релативно неутралан. Усредњавањем се такви кључни сигнали разводњавају заједно са неутралним говором. Због тога ће наредни приступи покушати да реше ове проблеме увођењем механизма пажње који омогућавају додељивање различитих тежина различитим прозорима говора.

4.3.1.4 Архитектуре базиране на дубоком учењу над Трансформер обележјима

Уместо директног примењивања једноставних ML алгорита на извучена обележја, развијене су и напредне неуронске мреже које уче да на паметнији начин комбинују извучена дубока обележја:

- **Аутоенкодер и сажимање пажњом:** Овај приступ користи излазна обележја Audeering модела. Прво се тренира аутоенкодер за уклањање шума (енг. *Denosing Autoencoder*) како би се смањила димензионалност излазних вектора на 200 карактеристика. Током његовог тренирања, на улаз се додаје Гаусов шум малог интензитета, а оптимизација се врши уз MSE функцију губитка за реконструкцију оригинала. Затим се тако сажети вектори прослеђују кроз прилагођену мрежу (*AttentionPoolRegressor*) која користи механизам пажње за сажимање (енг. *Attention Pooling*). Овај слој не користи *Self-Attention*, већ учи да додели већу тежину оним временским прозорима који садрже највише депресивних индикатора, правећи пондерисану суму свих прозора. Добијени агрегирани вектор се потом прослеђује кроз потпуно повезане слојеве за финалну регресију уз Хуберову функцију губитка (енг. *Smooth L1 Loss*).
- **Трансформер над Трансформером:** Овај приступ узима директно секвенцу екстрахованих вектора из Audeering модела за једног пацијента и пропушта их кроз додатни Трансформер енкодер (енг. *TransformerEncoder*). Захваљујући његовом механизму вишеструке пажње (енг. *Multi-Head Self-Attention*), мрежа је у стању да ухвати дугорочне временске зависности и контекст између различитих прозора у говору. Након енкодера, следи идентичан слој пажње за сажимање као у претходном приступу, који секвенцу своди на један вектор за финалну регресију.

Обе мреже тренирају се као ансамбл од 5 модела како би се повећала робусност и смањила варијанса у предвиђањима.

4.3.1.5 Анализа емоција у временским прозорима

Овај приступ ослања се директно на класификацију емоција за сваки прозор говора. Коришћен је модел `ehcalabres/wav2vec2-lg-xlsr-en-speech-emotion-recognition` који за прозоре од 5 секунди враћа вероватноће за 8 различитих емоција (љутња, смиреност, гађење, страх, срећа, неутралност, туга, изненађење). За цео аудио запис се онда рачунају статистике из ових вероватноћа по прозорима (средња вредност, минимум, максимум, стандардна девијација) и формира се коначни вектор вероватноћа који се прослеђује класичним регресионим алгоритмима.

4.3.2 Текстуални модели

Овај модул система фокусира се искључиво на анализу транскрипата клиничких интервјуа. У оквиру овог модула испробано је неколико различитих приступа, почевши од традиционалних модела, напредних језичких Трансформера и директних питања великих језичких модела (енг. *Large Language Model*, LLM).

4.3.2.1 Традиционални модели и TF-IDF репрезентација

Код овог приступа, транскрипт пацијента се дели на токене уз уклањање неалфанумеричких карактера и претварање свих слова у мала слова. Примењује се лематизација

и уклањају се стоп-речи. Обрађен текст векторизује се помоћу TF-IDF векторизације. Како би се смањила димензионалност и спречило преприлагођавање, примењује се математичка техника која из добијене високодимензионалне матрице издваја најважније скривене семантичке концепте (енг. *Latent Semantic Analysis*). Ова метода сажима податке у компактну репрезентацију, задржавајући кључне везе између речи уз истовремено уклањање шума, чиме се добија финална репрезентација за алгоритме регресије.

4.3.2.2 Комбиновани TF-IDF и Трансформер приступ

Овај приступ је хибридна метода која прво користи TF-IDF векторизацију, како би се идентификовало 200 најрелевантнијих лематизованих речи у читавом корпусу над тренинг скупом. Затим се за сваког пацијента његов транскрипт редукује само да садржи тих 200 најрелевантнијих речи. Такав транскрипт се затим пропушта кроз `all-mpnet-base-v2` Трансформер модел. Овако добијена густа репрезентација фокусирана искључиво на кључне речи се на крају користи у класичним ML регресорима.

4.3.2.3 Напредни језички Трансформери са традиционалним регресорима

Како би се сачувао контекст и редослед речи, коришћени су претходно тренирани Трансформер модели за генерисање густих репрезентација целих реченица и пасуса. Због ограничења Трансформера у дужини текста као улаза, транскрипти се деле на мање сегменте (енг. *chunks*) са преклапањем. За сваки сегмент генерише се ембединг помоћу Трансформера. Ембединзи свих сегмената једног пацијента се усредњавају у један финални вектор и прослеђују ML алгоритмима. Испробана су два Трансформер модела на овај начин:

- **all-mpnet-base-v2:** Одабран је јер представља један од најснажнијих модела из породице *Sentence-Transformers*. За разлику од стандардних Трансформера, он је експлицитно трениран да мапира читаве реченице или пасусе у висококвалитетне густе векторе који чувају дубље семантичко значење. Због тога је изузетно погодан за екстракцију информација из дужих сегмената текста.
- **bert-base-uncased:** Одабран је као основни (енг. *baseline*) модел за разумевање природног језика. Ово је један од најпознатијих и најчешће коришћених модела. Иако није специфично оптимизован за генерисање репрезентација целих реченица као MPNet, његово укључивање служи као одлична референца за поређење и проверу да ли специјализовани модели заиста доносе значајна побољшања на овом задатку.

4.3.2.4 Регресија заснована на емоцијама у тексту

Овај приступ је инспирисан сличном идејом као и код акустичких модела, али се примењује на текст. Транскрипт се дели на преклапајуће сегменте, а за сваки сегмент се позива модел `j-hartmann/emotion-english-distilroberta-base`. Овај модел враћа дистрибуцију вероватноћа за 7 различитих емоција. Вероватноће свих сегмената

се усредњавају, чиме се пацијент представља преко свог “емоционалног профила” (вектор од 7 елемената), који потом служи као улаз за традиционалну ML регресију.

4.3.2.5 Анализа лингвистичких карактеристика

Овде је покушано обогаћивање дубоких репрезентација експлицитним лингвистичким правилима. За сваки транскрипт се паралелно екстрахују семантички Трансформер вектори и мануелно дефинисане карактеристике (попут броја јединствених речи и стопе појављивања речи повезаних са негативним емоцијама из унапред дефинисаног речника). Ова два скупа карактеристика се конкатенирају пре уласка у коначни регресор ML.

4.3.2.6 Фино подешавање Трансформера (енг. Fine-Tuning)

Овде се користи приступ дубоког учења с краја на крај (енг. *end-to-end*). Модел *distilroberta-base* се фино подешава директно за задатак регресије. Транскрипти су подељени у сегменте од 150 речи (са преклапањем од 100 речи), где сваки сегмент наслеђује исти RNQ-8 скор као и цео транскрипт. Модел се тренира коришћењем HuggingFace Trainer АПИ-ја уз средњу апсолутну грешку (MAE) као метрику. Током евалуације, предвиђања за све сегменте једног пацијента се агрегирају (усредњавањем) како би се добио коначни скор. Не шаље се ништа даљим алгоритмима регресије. Ово омогућава Трансформеру да прилагоди своје унутрашње тежине специфичном речнику депресивних пацијената.

4.3.2.7 Комплетне дубоке архитектуре са механизмом пажње

Циљ овог приступа био је изградити прилагођену PyTorch архитектуру која ће исправити мане претходних модела. За разлику од простог усредњавања сегмената, где се сваком сегменту додељује једнака тежина (важност) што доводи до тога да се кључни депресивни сигнали разводне заједно са неутралним говором, ова мрежа користи механизам пажње (енг. *Attention Pooling*) над извученим MPNet векторима.

Мрежа се састоји од слоја за рачунање пажње, у виду вишеслојног перцептрона (MLP) са Tanh активацијом, који рачуна “тежину” сваког појединачног сегмента текста. Додељивањем различитих тежина, систем прави пондерисани збир свих сегмената, формирајући јединствени сажети вектор пацијента. Након њега следи регресиона глава (енг. *regression head*) у виду засебног MLP слоја са ReLU активацијом. Мрежа се тренира уз MSE функцију губитка како би научила који делови интервјуа (нпр. када пацијент директно говори о симптомима) носе највише информација, и како би њима доделила највећу тежину.

Овај приступ је изузетно флексибилан. Након тренинга, финална предвиђања могу се добити директно из истрениране неуронске мреже, али се такође слој за пажњу може искористити да екстрахује сажете векторе који се потом прослеђују традиционалним ML регресорима (попут SVR-а) за доношење финалне одлуке.

4.3.2.8 Zero-shot учење помоћу великих језичких модела

Овде је имплементиран потпуно другачији приступ заснован на *Prompt* инжењерингу. Коришћен је велики језички модел `google/flan-t5-base`. Транскрипти су дељени на дугачке сегменте (око 300 речи) како би се уклопили у контекстни прозор. Уместо тренирања мреже, моделу је прослеђен системски упит са задатком да, у улози клиничког психолога, процени присутност сваког од 8 симптома депресије на скали од 0 до 3, на основу прочитаног текста. Модел користи своје опште знање о језику како би директно генерисао одговоре без икаквог додатног тренинга на овом скупу података. Финални скор добија се једноставним сабирањем оцена за свако појединачно питање (симптом) на нивоу сегмента, а потом просеком тих сума за целог пацијента. Овим се добија финална предикција и не шаље се ништа даљим алгоритмима регресије.

4.4 Регресиони алгоритми машинског учења

Након што су аудио и текстуални подаци претпроцесирани и након што су из њих извучена релевантна обележја, последњи корак у систему је предвиђање финалне R_{HQ}-8 оцене. За овај задатак коришћени су различити регресиони алгоритми машинског учења. Сви наведени алгоритми детаљније су теоријски објашњени у поглављу 2, док се овде даје преглед њихове примене у систему.

У свим модулима за анализу звука и текста имплементиран је заједнички механизам за евалуацију више алгоритама. Алгоритми који су тестирани за доношење финалне одлуке су:

- **Гребенаста (Ridge) регресија** – коришћена као основни линеарни модел са регуларизацијом.
- **Еластична мрежа (ElasticNet)** – коришћена због своје способности да балансира L_1 и L_2 регуларизацију.
- **Регресија потпорних вектора (SVR)** – један од најчешће коришћених и најуспешнијих алгоритама у овом раду, нарочито над акустичким обележјима, због своје ефикасности у високодимензионалним просторима.
- **Случајна шума (Random Forest) и Градијентно појачавање (Gradient Boosting)** – алгоритми засновани на ансамблима стабала одлучивања, коришћени због њихове способности да ухвате комплексне нелинеарне везе.
- **К најближих суседа (KNeighborsRegressor)** – тестиран у оквиру основних акустичких модела као једноставан алгоритам базиран на мери удаљености између инстанци.

Како би се за сваки од ових алгоритама пронашли оптимални хиперпараметри, коришћена је метода насумичне претраге (`RandomizedSearchCV`) из библиотеке `scikit-learn`. За сваки алгоритам вршена је насумична претрага уз вишеструку унакрсну валидацију. За одабир најбољег модела дефинисана је прилагођена функција скорa S (енг. *score*) која комбинује три метрике: средњу апсолутну грешку (MAE), кореновану

средњу квадратну грешку (RMSE) и Пирсонов коефицијент корелације (ρ). Примарни циљ претраге био је минимизација ове комбиноване вредности, израчунате према формули:

$$S = \text{MAE} + 0.6 \cdot \text{RMSE} - 10 \cdot \rho$$

Оваква функција кажњава велика одступања (путем RMSE), док истовремено снажно награђује корелацију између предвиђених и стварних оцена. Регресор са комбинацијом хиперпараметара који је остварио најбоље резултате (најмању вредност функције S) током ове претраге (енг. *best estimator*) одабран је као финални модел, након чега је евалуиран на издвојеном тест скупу. Овакав приступ осигурава да се перформансе модела мере објективно и значајно смањује ризик од преприлагођавања (енг. *overfitting*) модела на податке за тренирање.

Глава 5

Верификација и валидација

У закључку дајте кратак преглед онога шта урађено, са освртом на проблеме који су решени, предности и мане решења и правце даљег развоја.

Глава 6

Закључак

У закључку дајте кратак преглед онога шта урађено, са освртом на проблеме који су решени, предности и мане решења и правце даљег развоја.

Списак слика

Слика 1	Ток података на високом нивоу	18
Слика 2	Хистограм дистрибуције RHQ-8 оцена на тренинг и валидационом спојеном скупу	19
Слика 3	Диструбиција броја речи по транскрипту интервјуа	19

Списак листинга

Списак коришћених скраћеница

Скраћеница	Опис
API	Application Programming Interface (апликациони програмски интерфејс)
AWS	Amazon Web Services (Амазон веб сервиси)
CI/CD	Continuous Integration / Continuous Delivery (континуирана интеграција / континуирана испорука)
CORS	Cross-Origin Resource Sharing (размена ресурса између извора и дестинације различитог порекла)
CSS	Cascading Style Sheets (језик за описивање стилова)
DOM	Document Object Model (објектни модел документа)
DTO	Data Transfer Object (објекат за пренос података)
HTTP	HyperText Transfer Protocol (протокол за пренос хипертекста)
JSON	JavaScript Object Notation (формат за размену података)
JWT	JSON Web Token (сигурносни токен заснован на JSON формату)
RLS	Row-Level Security (сигурност на нивоу реда)
REST	Representational State Transfer (скуп правила за комуникацију између клијента и сервера)
RPC	Remote Procedure Call (позив удаљене процедуре)
SQL	Structured Query Language (структурирани упитни језик)
TLS	Transport Layer Security (безбедност транспортног слоја)
UML	Unified Modeling Language (језик за моделовање дијаграма)
URL	Uniform Resource Locator (јединствени идентификатор и локатор ресурса)
UI	User Interface (кориснички интерфејс)
UUID	Universally Unique Identifier (универзално јединствени идентификатор)
WAL	Write-Ahead Logging (записивање операција унапред)

Списак коришћених појмова

Појам	Објашњење
Асинхрони рад	Рад који се изводи независно од главног тока извршавања, омогућавајући наставак других операција без чекања на његов завршетак.
Bucket (S3)	Логичка јединица за складиштење у AWS S3 сервису, која организује фајлове у облаку.
Read-Only	Режим рада у коме су подаци само за читање, без могућности измене.
Cross-platform	Способност софтвера да се извршава на више различитих оперативних система из истог кода.
Connection pool	Механизам за управљање и поновну употребу веза са базом података како би се побољшале перформансе апликације.

Биографија

Рођен сам у Новом Саду, 1. марта 2003. године. Са седам година сам се уписао у ОШ „Жарко Зрењанин”. Током тог периода био сам одличан ученик, председник разреда, председник ђачког парламента, члан школског одбора, „звезда толеранције”, као и учесник многих представа и манифестација. Оно што ме је посебно обележило било је учешће на такмичењима, највише из математике и информатике, али и из хемије и спорта. Из ових предмета сам освајао награде и на државном нивоу. Након осам година школовања, проглашен сам за ђака генерације.

По завршетку основне школе уписао сам Гимназију „Јован Јовановић Змај”, одељење за ученике са посебним способностима за рачунарство и информатику, и то као ученик са највише бодова на пријемном испиту. Мој фокус је био на истраживању и унапређењу вештина из програмирања и математике. Врло успешно сам се такмичио из математике и пливања, а једна од награда са математичких такмичења ослободила ме је полагања пријемног испита за Факултет техничких наука Универзитета у Новом Саду. Ипак, оно на шта сам највише поносан из тог периода јесте чињеница да сам упознао прегршт добрих људи и развио се као човек.

Своје образовање наставио сам на Факултету техничких наука Универзитета у Новом Саду, где сам уписао смер Софтверско инжењерство и информационе технологије, по мом мишљењу један од најбољих информатичких програма у Србији. Иако је фокус програма на софтверском инжењерству (енг. *software engineering*), моји омиљени предмети били су машинско учење (енг. *machine learning*), рачунарска интелигенција (енг. *computational intelligence*), као и алгоритми и структуре података – области у којима се математички принципи укрштају са софтверским приступима. Кроз ове курсеве реализовао сам занимљиве пројекте из вештачке интелигенције (енг. *Artificial Intelligence*), што је кулминирало овим дипломским радом.

Ван факултетских обавеза, константно радим на личном и професионалном усавршавању. Самостално сам реализовао неколико пројеката, међу којима се истиче развој апликације која данас организује рад једне грађевинске компаније. Након тога, добио сам прилику за четворомесечну праксу у компанији *Microsoft*, где сам радио на интеграцији и развоју нових функционалности вештачке интелигенције (енг. *AI features*) у програму *Microsoft Word*. Ово искуство ме је научило како да декомпонујем сложене задатке и ефикасно комуницирам у великим, дистрибуираним тимовима. Затим сам провео седам месеци на пракси у компанији *JetBrains*, у тиму који развија *AI Assistant*. Мој рад тамо био је фокусиран на функционалности које користе моделе вештачке интелигенције (енг. *AI models*) и евалуацију тих модела. Научио сам да самостално

развијам те функционалности и критички размишљам о новим решењима вештачке интелигенције (енг. *AI solutions*). Поред пракси, учествовао сам на три хакатона (енг. *hackathon*) – у Барселони, Минхену и Кошицама – где сам стекао искуство у брзом осмишљавању, имплементацији и презентовању софтверских решења у кратком временском року. Такође, похађао сам и летњу школу математике у Љубљани.

Пливање је спорт који сам професионално тренирао дванаест година и који ми је донео много радости и задовољства. Обишао сам многе градове у земљи и иностранству, упознао прегршт дивних младих људи, освојио више од сто медаља и био учесник развојног кампа Пливачког савеза Србије, који је похађало дванаест најбољих кадета. Увек сам био максимално посвећен тренинзима и такмичењима, што ми је дефинитивно изградило добре радне навике.

Уопштено, занимају ме разне области и сфере живота, а посебно програмирање, музика, биологија, медицина, спорт и математика. Кроз живот су ме увек покретали радозналост, жеља за решавањем проблема и континуирано усавршавање. Због тога сам одлучио да образовање наставим на мастер програму из вештачке интелигенције у биомедицини на Техничком универзитету у Минхену. Посебно се радујем прилици да применим вештачку интелигенцију на значајне биомедицинске проблеме и на тај начин допринесем човечанству.

Литература

- [1] J. E. R. Bernard, “Depression: A review of its definition,” *MOJ Addict Med Ther*, vol. 5, no. 1, pp. 6–7, 2018.
- [2] A. Stringaris, “What is depression?,” *Journal of Child Psychology and Psychiatry*, vol. 58, no. 12, pp. 1287–1289, 2017.
- [3] L. S. Goldman, N. H. Nielsen, H. C. Champion, and A. M. A. Council on Scientific Affairs, “Awareness, diagnosis, and treatment of depression,” *Journal of general internal medicine*, vol. 14, no. 9, pp. 569–580, 1999.
- [4] A. Pan, M. B. Abisado, R. Wang, and N. Wang, “Audio depression recognition based on deep learning,” in *Workshop on Electronics Communication Engineering (WECE 2024)*, Mar. 2025, pp. 31–40.
- [5] F. S. Alhussen, “Linguistic Feature-based Depression Prediction Using Hierarchical Transformer-attentive Model for Mental Disabilities Diagnosis,” *Journal of Disability Research*, vol. 4, no. 5, 2025.
- [6] K. Kroenke, T. W. Strine, R. L. Spitzer, J. B. Williams, J. T. Berry, and A. H. Mokdad, “The PHQ-8 as a measure of current depression in the general population,” *Journal of affective disorders*, vol. 114, no. 1–3, pp. 163–173, 2009.
- [7] N. Cummins, S. Scherer, J. Krajewski, S. Schnieder, J. Epps, and T. F. Quatieri, “A review of depression and suicide risk assessment using speech analysis,” *Speech Communication*, vol. 71, pp. 10–49, 2015.
- [8] M. Labied, A. Belangour, M. Banane, and A. Erraissi, “An overview of automatic speech recognition preprocessing techniques,” in *2022 international conference on decision aid sciences and applications (DASA)*, 2022, pp. 804–809.
- [9] L. Muda, M. Begam, and I. Elamvazuthi, “Voice recognition algorithms using mel frequency cepstral coefficient (MFCC) and dynamic time warping (DTW) techniques,” *Journal of Computing*, vol. 2, no. 3, pp. 138–143, 2010.
- [10] A. Baeovski, Y. Zhou, A. Mohamed, and M. Auli, “wav2vec 2.0: A framework for self-supervised learning of speech representations,” *Advances in neural information processing systems*, vol. 33, pp. 12449–12460, 2020.
- [11] W. N. Hsu, B. Bolte, Y. H. H. Tsai, K. Lakhota, R. Salakhutdinov, and A. Mohamed, “HuBERT: Self-supervised speech representation learning by masked prediction of

-
- hidden units,” *IEEE/ACM Transactions on Audio, Speech, and Language Processing*, vol. 29, pp. 3451–3460, 2021.
- [12] S. Chen *et al.*, “Wavlm: Large-scale self-supervised pre-training for full stack speech processing,” *IEEE Journal of Selected Topics in Signal Processing*, vol. 16, no. 6, pp. 1505–1518, 2022.
- [13] J. Wagner *et al.*, “Dawn of the transformer era in speech emotion recognition: closing the valence gap,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 45, no. 9, pp. 10745–10759, 2023.
- [14] G. Salton and C. Buckley, “Term-weighting approaches in automatic text retrieval,” *Information processing & management*, vol. 24, no. 5, pp. 513–523, 1988.
- [15] A. Vaswani *et al.*, “Attention is all you need,” *Advances in neural information processing systems*, vol. 30, 2017.
- [16] J. Devlin, M. W. Chang, K. Lee, and K. Toutanova, “BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding,” *arXiv preprint arXiv:1810.04805*, 2018.
- [17] J. Hartmann, M. Heitmann, C. Siebert, and C. Schamp, “More than a feeling: Accuracy and application of sentiment text analysis,” *International Journal of Research in Marketing*, vol. 40, no. 1, pp. 75–87, 2023.
- [18] Y. Liu *et al.*, “Roberta: A robustly optimized bert pretraining approach,” *arXiv preprint arXiv:1907.11692*, 2019.
- [19] K. Song, X. Tan, T. Qin, J. Lu, and T. Y. Liu, “MPNet: Masked and permuted pre-training for language understanding,” *Advances in Neural Information Processing Systems*, vol. 33, pp. 16857–16867, 2020.
- [20] H. W. Chung *et al.*, “Scaling instruction-finetuned language models,” *arXiv preprint arXiv:2210.11416*, 2022.
- [21] T. Brown *et al.*, “Language models are few-shot learners,” *Advances in neural information processing systems*, vol. 33, pp. 1877–1901, 2020.
- [22] A. E. Hoerl and R. W. Kennard, “Ridge regression: Biased estimation for nonorthogonal problems,” *Technometrics*, vol. 12, no. 1, pp. 55–67, 1970.
- [23] H. Zou and T. Hastie, “Regularization and variable selection via the elastic net,” *Journal of the royal statistical society: series B (statistical methodology)*, vol. 67, no. 2, pp. 301–320, 2005.
- [24] D. J. MacKay, “Bayesian interpolation,” *Neural computation*, vol. 4, no. 3, pp. 415–447, 1992.

- [25] L. Breiman, “Random forests,” *Machine learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [26] J. H. Friedman, “Greedy function approximation: a gradient boosting machine,” *Annals of statistics*, pp. 1189–1232, 2001.
- [27] A. J. Smola and B. Schölkopf, “A tutorial on support vector regression,” *Statistics and computing*, vol. 14, no. 3, pp. 199–222, 2004.
- [28] G. Hinton, L. Deng, D. Yu, G. E. Dahl, and others, “Deep neural networks for acoustic modeling in speech recognition: The shared views of four research groups,” *IEEE Signal processing magazine*, vol. 29, no. 6, pp. 82–97, 2012.
- [29] J. Zhao, X. Mao, and L. Chen, “Speech emotion recognition using deep 1D & 2D CNN LSTM networks,” *Biomedical signal processing and control*, vol. 47, pp. 312–323, 2019.
- [30] V. Mitra, A. Tsiartas, and E. Shriberg, “Noise and reverberation effects on depression detection from speech,” in *2016 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, 2016, pp. 5795–5799.
- [31] D. Bzdok and A. Meyer-Lindenberg, “Machine learning for precision psychiatry: opportunities and challenges,” *Biological Psychiatry: Cognitive Neuroscience and Neuroimaging*, vol. 3, no. 3, pp. 223–230, 2018.
- [32] T. Chai and R. R. Draxler, “Root mean square error (RMSE) or mean absolute error (MAE)?-Arguments against avoiding RMSE in the literature,” *Geoscientific model development*, vol. 7, no. 3, pp. 1247–1250, 2014.
- [33] J. Benesty, J. Chen, Y. Huang, and I. Cohen, “Pearson correlation coefficient,” in *Noise reduction in speech processing*, Springer, Berlin, Heidelberg, 2009, pp. 1–4.
- [34] T. Alhanai, M. Ghassemi, and J. Glass, “Detecting depression with audio/text sequence modeling of interviews,” in *Interspeech 2018*, 2018, pp. 1716–1720.
- [35] J. Gratch *et al.*, “The Distress Analysis Interview Corpus of human and computer interviews,” in *LREC*, May 2014, pp. 3123–3128.
- [36] F. Ringeval *et al.*, “AVEC 2019 Workshop and Challenge: State-of-Mind, Detecting Depression with AI, and Cross-Cultural Affect Recognition,” in *Proceedings of the 9th International on Audio/Visual Emotion Challenge and Workshop*, 2019, pp. 3–12.
- [37] P. Kokol, M. Kokol, and S. Zagoranski, “Machine learning on small size samples: A synthetic knowledge synthesis,” *Science Progress*, vol. 105, no. 1, p. 00368504211029777, 2022.